



TRABAJO PRÁCTICO nº3

Facultad de Ciencias Económicas

Universidad de Buenos Aires

Big data & Machine learning

Código de materia/Curso: Nro 557/2. Prof. Romero, Noelia


Integrantes: Herrero, Facundo (913362), Pougy, Santiago (897575) y da torre, Juan Ignacio (910183)

**HISTOGRAMAS, KERNELS & MÉTODOS NO SUPERVISADOS
USANDO LA EPH**

Parte I: Creación de variables, histogramas, kernels y resumen de la base de datos final

La idea de esta primera parte es que completen la limpieza de la base de datos que contiene las observaciones del primer trimestre de 2005 y del primer trimestre de 2025. La **base final** a trabajar resultante debe incluir todas las variables presentes en ambos trimestres, expresadas de manera homogénea. Es decir, si la variable CH04 en 2005 toma los valores “Hombre” o “Mujer”, y en 2025 toma los valores 1 y 2, la variable limpia en la **base final** debe tener solamente dos valores consistentes.

1. Cree la variable “*edad2*” definida como $edad^2$ (edad al cuadrado). Presente un histograma de la variable edad en un panel A, y a la par una distribución de kernels para los pobres y no pobres en un panel B (esto es, son dos líneas de kernel en este segundo panel). Comente brevemente la distribución de edades en estos dos paneles (3-4 oraciones).



El Panel A muestra que la distribución de la edad es amplia, con mayor frecuencia entre los 20 y 50 años, y una menor presencia de personas mayores de 70. En el Panel B, la densidad kernel indica que los pobres se concentran en edades más jóvenes, con un pico pronunciado cerca de los 20 años, mientras que los no pobres tienen una distribución más extendida y con mayor densidad en edades medias. Esto sugiere que la pobreza afecta proporcionalmente más a personas jóvenes. En conjunto, los gráficos reflejan una población


económicamente activa más envejecida entre los no pobres y más juvenil entre los pobres.

2. Cree la variable *educ* definida como la cantidad de años de educación. Use inteligentemente las variables CH12, CH13 y CH14 para crearla. Por ejemplo, si dice que el nivel más alto de educación es “Secundario” (CH12), “Sí” finalizó este nivel (CH13) y el último año que aprobó (CH14) fue “sexto”, entonces puede asumir que tiene *educ*=12, osea 12 años de educación formal. Presente una estadística descriptiva (promedio, sd, min, p50, max) de dicha variable creada y comente

Medida	Valor
Promedio	10.97
Desvío estándar	5.27
Mínimo	0.00
Mediana (p50)	12.00
Máximo	17.00

En promedio, los individuos tienen cerca de 11 años de educación formal, lo que equivale aproximadamente al nivel secundario completo. La mediana confirma esta concentración en torno a la educación media. El rango es amplio, desde personas sin escolaridad hasta aquellas con estudios universitarios o superiores. La dispersión moderada (desvío estándar $\approx 5,3$) indica una heterogeneidad significativa en los niveles educativos dentro de la muestra.

3. Actualice la variable *ingreso_total_familiar* con el total de ingresos habituales (ITF). Recuerde que los pesos de 2005 tienen un poder de compra distinto a los pesos de 2025 en el primer trimestre. Convierta primero los ingresos de 2005 a pesos de 2025. Similar al ítem 1, presente en un panel A, un histograma de la variable *ingreso_total_familiar* y las distribuciones de kernels para pobres y no



pobres en un panel B. Comente brevemente la distribución de ingresos en estos dos panels (3-4 oraciones). En cada panel, sume una línea vertical con la línea de la pobreza calculada en el TP2.

El Panel A muestra una distribución fuertemente asimétrica hacia la derecha: la mayoría de los hogares tiene ingresos bajos, concentrados por debajo de la línea de pobreza, y pocos alcanzan niveles altos de ingreso. En el Panel B, la densidad kernel evidencia que los pobres se agrupan cerca de cero, mientras que los no pobres presentan una distribución más extendida con un pico por encima de la línea de pobreza. La diferencia entre ambas curvas refleja una marcada desigualdad en la distribución del ingreso. En conjunto, los gráficos indican una alta concentración de hogares en el tramo de bajos ingresos y una brecha clara entre pobres y no pobres.

- Para el jefe del hogar, cree la variable *horastrab* como el total de horas trabajadas como la suma de las horas en la ocupación principal y otras ocupaciones (PP3E_TOT + PP3F_TOT). Presente una estadística descriptiva (promedio, sd, min, p50, max) de dicha variable creada y comente

Medida	Valor
Observaciones	10 553
Promedio	15.94
Desvío estándar	22.58
Mínimo	0.00
Percentil 25	0.00
Mediana (p50)	0.00
Percentil 75	40.00
Máximo	105.00

La distribución de horas trabajadas es altamente asimétrica, con una gran proporción de personas que no registran horas trabajadas en la semana (mediana igual a 0. El promedio se ve influido por un grupo con jornadas extensas, alcanzando hasta 105 horas. La dispersión es elevada, lo que refleja heterogeneidad en la inserción laboral. En conjunto, los datos sugieren una coexistencia entre inactividad o desempleo y jornadas laborales intensas entre quienes sí trabajan.

- ¿Cuál es el tamaño de la de la base de datos **para su región** con las variables originales unificadas? Para ello complete la tabla 1 que se le diseña abajo y comente.

Tabla 1. Resumen de la base final para la región YYY

	2005	2025	Total
--	------	------	-------

Cantidad observaciones	7984	2623	10607
Cantidad de observaciones con NAs en la variable “Pobre”	0	0	0
Cantidad de Pobres	1021	467	1488
Cantidad de No Pobres	6963	2156	9119
Cantidad de variables limpias y homogeneizadas	31	31	31


La base unificada cuenta con 10 607 observaciones totales, sin valores faltantes en la variable *pobre*. En 2005 se identifican 1 021 pobres (12,8 %) y en 2025 467 pobres (17,8 %), mostrando un aumento en la incidencia de la pobreza. La cantidad de variables limpias y homogéneas se mantiene constante en 31, lo que garantiza comparabilidad entre años. En conjunto, la tabla evidencia un deterioro relativo de las condiciones económicas en la muestra analizada.

Parte II: Métodos No Supervisados

Esta parte del trabajo práctico tiene como objetivo que realicen un análisis visual de los datos utilizando las herramientas vistas en clase. En esta parte, solo necesita utilizar las variables: edad, edad2, educ, ingreso_total_familiar (ITF), el número de miembros en el hogar (2005=IX_TOT y 2025=IX_Tot) y horastrab.


1. Realice una matriz de correlaciones con estos seis predictores para su región y comente los resultados.
 - Lo que se puede observar en la siguiente imagen es la relación que hay entre las variables. Entre ellas las que poseen “1” son aquellas que tienen relación con su misma variable, no tiene mucho análisis dado que es la variable idéntica. Ahora por otro lado, podemos destacar la correlación de dos variables. La más obvia sería $Edad^2$ donde posee una relación de con edad. Esto debido a que es la misma variable, pero al cuadrado, será de utilidad para suavizar una regresión lineal en un eventual caso. Luego la relación de edad y $Edad^2$ con educación es de 38% para el primer caso y 21% para el segundo, un número que nos llamó la atención debido a que la educación tiene una relación con la edad la probabilidad de que a ser más grande tenga más estudios es creciente. Por último, hay una correlación positiva del 14% entre educación y ingreso total familiar, el análisis que podríamos hacer es que tener una persona con mayor nivel de educación en la familia podría ayudar en términos económicos al desarrollo de la familia.

Para finalizar, como vemos las demás variables tienen una correlación extremadamente débil y en algunos casos negativa que carecen de un análisis fundamental.



A. PCA

2. PCA con ingreso: Apliquen PCA a las seis variables seleccionadas para esta parte. Recuerde primero estandarizar las variables como vimos en la tutorial. En un gráfico de dispersión muestren los índices (*scores*) calculados del primer y segundo componente de PCA y comente los resultados.
 - Al aplicar PCA a las variables seleccionadas, primero debemos estandarizar las variables con el propósito de que todas las variables contribuyan de manera equitativa. Ahora una vez estandarizadas vemos un gráfico de dispersión o scatterplot vemos que la dispersión de los datos esta mas a lo ancho que a lo largo, es decir, tiene una predominancia sobre el eje de abscisas que sobre el eje de las ordenadas. Esto denota que el componente numero 1 captura más información (o varianza) que el componente numero 2




3. Grafique con flechas los ponderadores (*loading*) de PCA para el primer y segundo componente y comente los pesos que le dan a cada variable utilizada.
 - Una vez normalizadas las variables, toca aplicarle los ponderadores para así analizar los vectores. Comenzando por el peso de las variables en cada componente vemos que mientras en el primer componente las 2 edades y la educación explican prácticamente todo el componente, a diferencia del otro componente donde el ingreso total familiar explica prácticamente todo

```



Loadings del Componente Principal 1:
edad: 0.622
edad2: 0.597
educ: 0.337
ITF: 0.050
n_personas: -0.374
horastrab: -0.010

Loadings del Componente Principal 2:
edad: -0.163
edad2: -0.243
educ: 0.439
ITF: 0.834
n_personas: -0.151
horastrab: -0.048
  
```



Por otro lado, vemos el gráfico con los ponderadores y sus respectivas flechas. El análisis de componentes principales revela dos ejes interpretables: el **Componente 1**, dominado por las variables de **edad y educación**, refleja un patrón asociado al **ciclo de vida y capital humano**, diferenciando a individuos mayores y más educados de los más jóvenes o con hogares numerosos; mientras que el **Componente 2**, definido principalmente por el **ingreso total familiar (ITF)** y la educación, representa un **eje de estatus económico**. En el plano CP1–CP2, los individuos ubicados hacia la derecha son mayores y más educados, y los que se sitúan hacia arriba presentan mayores niveles de ingreso. Por otro lado, *n_personas* y horas trabajadas tienen poco aporte en términos de varianza y es por ello que tienen vectores más cortos.

4. Finalmente, grafique la proporción de la varianza explicada para cada uno de los seis componentes y comente el gráfico.
 - a. Llegando a lo último que respecta a PCA, resta analizar la varianza explicada que nos determina cuanto aporte de explicación de datos tiene cada variable que analizamos. En principio tan solo una variable explica casi el 40% de nuestros datos, y 3 variables el 73% de estos. Lo que podemos observar es que si bien a medida que agregamos más variables explicamos más, la última variable tiene poco peso relativo de varianza explicada y las anteriores están en un promedio de 15% de explicación.




B. Cluster



5. Cluster k-medias:

- Corran el algoritmo con $k = 2$, $k = 4$ y $k = 10$ usando `n_init = 20`, y grafiquen los resultados usando edad e ingreso familiar. Interprétenlos ¿Puede el algoritmo con $k = 2$ separar correctamente a las personas pobres y no pobres en su región?

Se estimaron modelos **k-means** con $k = 2, 3$ y 4 utilizando `n_init = 20` para asegurar la estabilidad de los resultados.

Los resultados se visualizaron en el plano **Edad-ITF**, coloreando las observaciones según el grupo asignado por el algoritmo.





El modelo con $k = 2$ muestra una división parcial entre individuos de bajos y altos

ingresos, evidenciando una separación influenciada principalmente por el ITF.


Con $k = 3$, los grupos se vuelven más interpretables: uno concentra a individuos de ingresos bajos, otro a la clase media y un tercero a los de mayores ingresos, reflejando una estructura socioeconómica tripartita.

El modelo con $k = 4$ añade un nivel de segmentación adicional, aunque sin un aumento sustancial en la interpretabilidad. Por ello, desde el punto de vista analítico y gráfico, $k = 3$ resulta el valor más parsimonioso.

- b. Grafique alguna medida de disimilitud para $k = 1$ hasta $k = 10$. Usando la inspección visual de *Elbow* ¿cuál sería el número óptimo de clusters en su región? ¿Dicha cantidad de grupos nos ayudaría a distinguir entre *pobres* y *no pobres* o entre distintas clases socioeconómicas?

Para determinar el número óptimo de clusters, se aplicó el método del **codo** calculando la inercia total para k entre 1 y 10.


El punto de inflexión del gráfico se observa aproximadamente en $k = 3$, lo cual sugiere que tres grupos capturan adecuadamente la heterogeneidad de los datos sin sobreajustar.



Este resultado coincide con la interpretación visual de los gráficos Edad-ITF, donde la segmentación con tres clusters separa razonablemente los distintos niveles de ingreso y tipo de hogar.

6. Cluster jerárquico: Utilizando las variables mencionadas arriba, realicen un análisis de clustering jerárquico. Generen un dendrograma y expliquen brevemente qué es un dendrograma.

El dendrograma obtenido permite visualizar cómo las observaciones se van fusionando a medida que aumenta la distancia de similitud, mostrando una estructura anidada de los grupos.



A partir del dendrograma, se observa que la separación natural también sugiere alrededor de **tres conglomerados principales**, lo cual es consistente con el análisis previo de k-means.

Los clusters pueden interpretarse como representaciones de distintas clases socioeconómicas —baja, media y alta— en lugar de una división estricta entre pobres y no pobres.

7. (Opcional) Cluster k-moda: Implemente cluster k-moda con $k = 2$, $k = 4$ y $k = 10$ y todas las variables **dummies** de la EPH que tiene en su base de datos limpias (excepto la categorica pobre y no pobre). ¿Puede el algoritmo con $k = 2$ separar correctamente a las personas pobres y no pobres en su región?

No se implementó el método **k-moda** dado que la base trabajada contiene principalmente variables numéricas continuas, y los objetivos del trabajo se centran en la aplicación de PCA y *k-means* para dichas variables. En un análisis posterior podría incorporarse k-moda sobre variables categóricas dummies para evaluar patrones adicionales.