



TRABAJO PRÁCTICO n°4

Facultad de Ciencias Económicas

Universidad de Buenos Aires

"Clasificación de pobres"



Big data & Machine learning

Código de materia/Curso: Nro 557/2. Prof. Romero, Noelia

Integrantes: Herrero, Facundo (913362), Pougy, Santiago (897575) y da torre, Juan ignacio (910183)

A. Enfoque de validación

No hay diferencias estadísticamente significativas entre las medias de las variables del conjunto de entrenamiento y del conjunto de testeo.

En 2005, todas las variables presentan valores p superiores a 0.30, y en 2025 sólo una (Distinción_vivienda_hogar) muestra un p-valor cercano a 0.02, pero el resto supera ampliamente el umbral de 0.05.

Esto indica que las medias son muy similares entre ambas particiones y que la división 70/30 preservó la representatividad de la muestra, sin sesgos relevantes entre los grupos de entrenamiento y prueba.

B. Modelo de regresión Logística

3. Como se observa en la tabla, contamos con diversas variables explicativas que influyen en la probabilidad del evento de pobreza. En primer lugar, identificamos que las variables **edad**, **parentesco**, **tipo_cobertura_salud**, **obra_social**, **nivel_ocupacion**, **tipo_contrato**, **busqueda_empleo**, **n_personas**, **adulto_equiv** y **edad2** presentan **p-valores menores a 0.05**, por lo tanto, resultan **estadísticamente significativas** al 5%. Esto implica que dichas variables poseen poder explicativo dentro del modelo, mientras que las restantes no muestran evidencia estadística suficiente para afirmar un efecto claro sobre la probabilidad del suceso.

En cuanto a los **signos de los coeficientes**, podemos interpretar la dirección del impacto sobre la probabilidad de ser pobre. Por ejemplo, **edad** y **parentesco** presentan coeficientes positivos, indicando que, a mayor edad o posición de mayor jerarquía familiar, aumenta la probabilidad del evento, aunque en el caso de edad el efecto se modera por el término cuadrático (**edad²**, negativo), lo que sugiere un comportamiento no lineal: el riesgo aumenta hasta cierto punto y luego se reduce. En cambio, variables como **tipo_cobertura_salud**, **obra_social** y **nivel_ocupacion** tienen signo negativo, es decir, actúan como factores protectores que reducen la probabilidad de pobreza. Particularmente, **obra_social** reduce las odds de ser pobre en torno a un 41%, mientras que **tipo_cobertura_salud** lo hace en aproximadamente un 45%

Por otro lado, **busqueda_empleo** y **tipo_contrato** tienen un fuerte efecto positivo: las personas que están buscando empleo o poseen un tipo de contrato más precario muestran odds de pobreza considerablemente más altas (por ejemplo, buscar empleo multiplica las chances de pobreza por casi 3.8 veces). Asimismo, **adulto_equiv** tiene un impacto muy pronunciado: cada adulto equivalente adicional incrementa las odds del evento en más de 40 veces, reflejando el peso que tiene el tamaño y la composición del hogar sobre la situación económica.

Finalmente, respecto al **error estándar**, observamos que la mayoría de las variables presentan valores pequeños, lo que indica una estimación precisa de los coeficientes. La constante, aunque significativa, no tiene interpretación económica directa porque representa la probabilidad base de ser pobre cuando todas las variables valen cero, lo cual carece de sentido práctico.

Variable	Coefficiente	Error Std.	p-valor	Odds Ratio
constante	-5.5307	1.4974	0.0002	0.004
Distincion_vivienda_hogar	-0.1204	0.4528	0.7903	0.8866
genero	0.4514	0.2391	0.0591	1.5705
edad	0.0746	0.0328	0.0228	1.0774
tipo_empleo	0.0995	0.0638	0.1185	1.1047
parentesco	0.095	0.0313	0.0024	1.0996

nivel_educ	-0.001	0.0537	0.9851	0.999
estado_empleo	0.0047	0.2247	0.9834	1.0047
categoria_inactividad	0.3221	0.0838	0.0001	1.38
tipo_cobertura_salud	-0.6088	0.2573	0.018	0.544
obra_social	-0.5272	0.1658	0.0015	0.5903
nivel_ocupacion	-0.2445	0.1165	0.0359	0.7831
tipo_contrato	0.4144	0.0535	0	1.5134
empleo	0.1157	0.2278	0.6114	1.1227
busqueda_empleo	1.3359	0.3304	0.0001	3.8033
medio_busqueda_empleo	-11.6191	13313.004	0.9993	0
n_personas	0.3764	0.1885	0.0459	1.457
adulto_equiv	3.7627	1.0871	0.0005	43.065
ad_equiv_hogar	-0.2804	0.2278	0.2184	0.7555
edad2	-0.001	0.0004	0.0068	0.999
educ	-0.0519	0.0512	0.3108	0.9494
horastrab	-0.0187	0.0037	0	0.9815

4. Armamos una visualización donde presentamos un gráfico con la $\hat{P}(Y = 1|X)$ (en el eje vertical) y característica “Edad” la cual es numérica (en el eje horizontal). Como podemos observar al ser parte de una regresión logística el grafico esta acotado entre 0 y 1. Esto es así debido a que se asignan probabilidades de ser pobre según la edad de que uno tenga, y como bien sabemos las probabilidades van de 0 a 1. Se aprecia una **tendencia claramente decreciente**, lo que indica que, según el modelo, la probabilidad de ser pobre es **más alta en edades tempranas y disminuye progresivamente** a medida que aumenta la edad. En particular, entre los menores de 20 años las probabilidades tienden a concentrarse entre el **20% y el 30%**, mientras que para los adultos mayores (por encima de los 60 años) la probabilidad promedio cae por debajo del **10%**. Esto sugiere que el modelo asocia la juventud con una mayor vulnerabilidad económica, posiblemente reflejando menores ingresos, menor experiencia laboral o mayor dependencia del hogar, mientras que en edades más avanzadas la incidencia de la pobreza tiende a reducirse.




Gráfico I – Probabilidad estimada de ser pobre, fuente: INDEC 2025




Gráfico II – Curva logit, probabilidad acumulada, fuente: INDEC 2025

C. Método de vecinos Cercanos (KNN)

5. Se estimó un modelo de clasificación mediante el método de **K Vecinos Más Cercanos (KNN)** sobre la base respondieron_2025, probando distintos valores de K (1, 5 y 10) para analizar el **trade-off entre sesgo y varianza**. Con **K=1**, el modelo logra una *accuracy* cercana al 97%, aunque con sobreajuste y alta varianza; al aumentar K, las fronteras se suavizan, el modelo se vuelve más estable y generalizable, pero con ligera pérdida de precisión. De este modo, se evidencia que un **K intermedio** ofrece el mejor equilibrio entre precisión y robustez del modelo.

6. En este apartado se representaron gráficamente las **fronteras de decisión del modelo KNN** para los valores **K=1** y **K=10**, con el objetivo de analizar cómo varía la complejidad del clasificador según el número de vecinos considerados. Las visualizaciones se elaboraron sobre dos variables numéricas del conjunto respondieron_2025, mostrando en color rojo los casos clasificados como *pobres* y en azul los *no pobres*. En el caso de **K=1**, el modelo presenta **fronteras de decisión muy irregulares y fragmentadas**, donde cada punto del conjunto de entrenamiento influye fuertemente sobre la predicción. Esto implica una **alta varianza** y un claro riesgo de *sobreajuste*, ya que el modelo se adapta al ruido de los datos y pierde capacidad de generalización. Por el contrario, con **K=10**, las fronteras se vuelven **más suaves y continuas**, reflejando una mayor estabilidad en las predicciones. Sin embargo, al promediar la información de un número mayor de vecinos, el modelo gana **robustez** pero pierde detalle local, incurriendo en **mayor sesgo** y clasificando incorrectamente algunos casos cercanos a los límites entre grupos.

En conjunto, los gráficos evidencian el **trade-off entre sesgo y varianza**: valores pequeños de K producen modelos

más precisos pero inestables, mientras que valores grandes generan modelos más simples y generalizables, aunque menos sensibles a las particularidades de los datos. Este equilibrio es fundamental para lograr un desempeño óptimo en la predicción del estado de pobreza.




Gráfico III & IV – Vecinos cercanos, con variables de análisis edad y numero de personas para k=1 & k=10, fuente: INDEC 2025

7. En esta sección se aplicó validación cruzada (CV 5-fold) para determinar el valor óptimo de K en el modelo K-Vecinos Más Cercanos (KNN). El gráfico evidencia que la *accuracy* promedio alcanza su punto máximo en **K = 1**, disminuyendo progresivamente a medida que el número de vecinos aumenta. Esto refleja que valores bajos de K producen modelos con bajo sesgo y alta varianza, mientras que valores más altos generan mayor sesgo y menor varianza, es decir, modelos más estables pero menos ajustados a los datos.

Si bien el mejor rendimiento promedio se obtiene con $K = 1$, este valor implica un riesgo considerable de sobreajuste. En cambio, valores intermedios como $K \approx 3-4$ logran un compromiso más equilibrado entre precisión y capacidad de generalización.

Desde la perspectiva de la regla del codo, la curva de validación no presenta un punto de inflexión marcado; sin embargo, el aplanamiento de la tendencia alrededor de $K \approx 3$ puede interpretarse como un “codo” práctico, donde el modelo alcanza un equilibrio razonable entre complejidad y estabilidad predictiva.




Gráfico V – Vecinos cercanos, vecinos cercanos fuente: INDEC 2025

D. Modelo de regresión logística con Regularización: Ridge y LASSO

8.




Gráfico VI – Trayectoria de coeficientes L1 & L2, fuente: INDEC 2025

En el modelo LASSO (izquierda), se observa que algunos coeficientes, por ejemplo, el de *Distinción_vivienda_hogar* (línea azul) o *estado_empleo*, se reducen con rapidez hasta llegar exactamente a cero, lo que indica que el modelo deja de considerarlos relevantes. Este efecto de “apagado” es característico del LASSO, que además de penalizar la magnitud de los coeficientes, elimina variables con bajo poder explicativo, logrando un modelo más simple.

En cambio, en el modelo Ridge (derecha), esos mismos coeficientes se reducen de manera más gradual, sin anularse completamente. Por ejemplo, *Distinción_vivienda_hogar* mantiene un valor negativo que disminuye lentamente conforme aumenta la penalización, reflejando que Ridge suaviza la influencia de las variables, pero no las descarta.

Entonces mientras que LASSO realiza una selección explícita de variables, Ridge conserva todas pero con menor peso, logrando así mayor estabilidad en la estimación. Variables como *ad_equiv_hogar* o *educ* mantienen trayectorias alejadas de cero en ambos modelos, lo que evidencia su mayor relevancia en la explicación de la probabilidad del evento.

7. Como se puede observar en las siguientes dos imágenes se intenta obtener la restricción óptima en los modelos L1 & L2, donde en ambos casos (Para nuestra sorpresa) los valores arrojaron un $\lambda = 1 \times 10^{-1}$. Cada box plot muestra la distribución del **error de clasificación** (1 – Accuracy) para distintos valores de λ . Puede apreciarse que el error se mantiene **muy estable alrededor de 0.2**, lo que equivale a una **accuracy promedio del 80%**, independientemente del nivel de regularización aplicado. Esto indica que el modelo no es particularmente sensible al parámetro λ dentro del rango evaluado, lo cual sugiere que tanto la penalización L1 como L2 logran un comportamiento robusto y consistente en términos de desempeño predictivo.




Gráfico VII – Búsqueda óptima de λ en L1 & L2 con intervalos de confianza, fuente: INDEC 2025

En la siguiente figura se muestra la **proporción de variables ignoradas** en el modelo **LASSO (L1)** para distintos valores del parámetro de regularización λ . Se observa que, a medida que aumenta el nivel de penalización, la proporción de coeficientes reducidos a cero crece de forma considerable, alcanzando valores cercanos al **100% para los λ más altos**.

En el punto óptimo seleccionado por validación cruzada, la mayoría de las variables mantienen coeficientes distintos de cero, lo que sugiere que el modelo aún conserva información relevante sin eliminar completamente las variables explicativas.




Gráfico VIII – Proporción de variables ignoradas en L1, fuente: INDEC 2025

1.

Variable	Sin penalidad	LASSO (λ^{cv})	Ridge (λ^{cv})
constante	-1.917645	-2.437615	-1.632521
Distincion_vivienda_hogar	-0.474904	-0.140811	-0.401348
genero	0.325882	0.379418	0.151449
edad	0.076897	0.073574	0.091142
tipo_empleo	0.085488	0.094396	0.094747
parentesco	0.091084	0.095321	0.100013
nivel_educ	-0.031937	-0.012847	-0.039697
estado_empleo	-0.146709	-0.044678	-0.160215
categoria_inactividad	0.3847	0.327762	0.340147
tipo_cobertura_salud	-0.519991	-0.580965	-0.549665

2.

En la comparación de coeficientes se observa que la **regresión logística sin penalidad** muestra los valores originales estimados para cada variable, reflejando el modelo base sin restricciones.

Al incorporar la **penalización LASSO (L1)** con el valor óptimo λ_{cv} , aprecia una reducción en la magnitud de varios coeficientes, aunque **ninguno se anula completamente**. Esto indica que el nivel de regularización seleccionado fue **moderado**, permitiendo conservar todas las variables dentro del modelo, pero con menor peso relativo en aquellas de menor relevancia.

Por su parte, la **penalización Ridge (L2)** también suaviza los coeficientes, aunque de forma más homogénea, reduciendo ligeramente su magnitud sin llegar a eliminar ninguna variable. Este comportamiento es característico del Ridge, que **controla el sobreajuste** sin forzar la exclusión de predictores.

En síntesis, **LASSO introduce una mayor diferenciación entre variables al atenuar más fuertemente los coeficientes menos significativos**, mientras que **Ridge aplica una contracción más uniforme**, manteniendo la estabilidad del modelo y evitando la pérdida de información relevante.

Bonus “Elastic Net”: En este caso, el gráfico muestra cómo varían los coeficientes estimados de cada variable al modificar la proporción de penalización **L1 (LASSO)** frente a **L2 (Ridge)**, es decir, el parámetro **l1_ratio**. Se observa que solo un grupo reducido de variables principalmente **edad** y en menor medida **horastrab**, mantienen coeficientes distintos de cero a lo largo de las combinaciones, mientras que la mayoría de las demás variables son anuladas (coeficientes cercanos a cero) para todos los niveles de penalización.

A medida que aumenta la proporción de L1 (de 0.1 a 0.9), el coeficiente de **edad** se vuelve menos negativo, mostrando el efecto de **LASSO** al reducir los valores absolutos de los coeficientes hacia cero. Por su parte, **horastrab** conserva un valor negativo relativamente estable, aunque también tiende a disminuir en magnitud conforme crece la penalización L1





Gráfico V – penalización de variables en Elastic net, fuente: INDEC 2025


E. Desempeño de modelos afuera de la muestra, métricas y políticas públicas

II)

Matriz de confusión — Logit (umbral 0.5)



Curvas ROC — Test 2025



Modelo	Accuracy	F1
Logit	0.854	0.335
KNN (K-CV)	0.968	0.903
Logit LASSO (λ^{cv})	0.854	0.335
Logit Ridge (λ^{cv})	0.854	0.335

El modelo Logit muestra una accuracy de 0.85 y un F1 de 0.33. Su matriz de confusión indica buen desempeño al identificar no pobres (643 verdaderos negativos) pero menor capacidad para detectar pobres (29 verdaderos positivos y 99 falsos negativos), lo que sugiere baja sensibilidad.

El KNN con K-CV presenta un desempeño notablemente superior, con un AUC de 0.946, accuracy de 0.97 y F1 de 0.90, reflejando alta precisión y recall. Sin embargo, este resultado probablemente se deba a sobreajuste, ya que el modelo aprende patrones específicos del conjunto de entrenamiento.

Los modelos Logit LASSO (λ^{cv}) y Logit Ridge (λ^{cv}) obtienen métricas casi idénticas al logit tradicional (AUC $\approx$ 0.83), pero con menor riesgo de sobreajuste y mayor estabilidad.

En síntesis, aunque el KNN logra la mayor precisión numérica, el Logit penalizado (LASSO o Ridge) es más confiable para generalizar y explicar la probabilidad de pobreza, manteniendo un equilibrio entre desempeño, robustez e interpretabilidad.

12) Se compararon cuatro modelos: Logit simple, KNN con K-CV, Logit Ridge y Logit LASSO. El Logit simple es interpretable pero puede sobreajustar; el KNN logra alta precisión en entrenamiento pero generaliza mal y carece de interpretación; Ridge reduce el sobreajuste pero mantiene todas las variables; y LASSO simplifica el modelo al eliminar predictores irrelevantes, logrando buena precisión y estabilidad. Para el Ministerio de Capital Humano, que busca detectar hogares pobres y evitar falsos negativos (error tipo II), el Logit LASSO (λ^{cv}) es el más adecuado porque combina buena capacidad predictiva, simplicidad e interpretabilidad, permitiendo focalizar mejor los recursos alimentarios escasos.

13) El modelo seleccionado (Logit LASSO (λ^{cv})) identificó como pobres al 14.61% de las personas de la base norespondieron_2025, es decir, 78 de 534 individuos.

Esto significa que, según las características observadas en los hogares respondientes, el modelo estima que aproximadamente 1 de cada 7 personas no encuestadas se encuentra en situación de pobreza.

El resultado permite ampliar la cobertura de la política pública hacia casos no observados directamente, aprovechando el poder predictivo del modelo para focalizar los recursos alimentarios en los grupos más vulnerables.